شتاب‌دهنده‌های سخت‌افزاری

کامپیوتر دانشکده مهندسی

بهار ۱۴۰۳-۱۴۰۴

تمرین دوم

تاریخ انتشار : ۱۴۰۲/۱۲/۲۶ - تاریخ تحویل : ۱۴۰۳/۰۱/۰۸

هدف از این تمرین پیاده‌سازی و درک الگوریتم KMeans برای خوشه‌بندی داده‌های سوال زیر است.

توجه: پیاده‌سازی الگوریتم KMeans باید بدون استفاده از کتابخانه‌های آماده انجام شود و تنها از قابلیت‌های پایه‌ای زبان برنامه‌نویسی انتخابی خود استفاده کنید. با این حال، استفاده از Matplotlib، Numpy، Seaborn و Pandas صرفاً برای خواندن داده‌ها، نرمالسازی و نمایش نتایج مجاز است.

الگوریتم KMeans یکی از روش‌های یادگیری بدون نظارت است که با تقسیم داده‌ها به تعداد مشخصی خوشه، سعی می‌کند تشابه داده‌های داخل هر خوشه را بیشینه و تفاوت داده‌های متعلق به خوشه‌های مختلف را کمینه کند. این الگوریتم از یک معیار فاصله برای اندازه گیری تشابه داده‌ها استفاده می کند. الگوریتم KMeans به این صورت عمل می‌کند:

- ابتدا تعداد k نقطه را به صورت تصادفی انتخاب می‌کند و آن‌ها را به عنوان مراکز اولیه خوشه‌ها در نظر می‌گیرد.
- سپس هر داده را به نزدیک ترین مرکز خوشه اختصاص می دهد و برچسب خوشه آن را مشخص می کند.
- بعد از این که همه داده‌ها به خوشه ها تخصیص یافتند، مراکز خوشه‌ها را با محاسبه میانگین داده‌های هر خوشه به روز می‌کند.
- این مراحل را تا زمانی که مراکز خوشه‌ها تغییر نکنند یا تعداد مشخصی تکرار انجام شود، تکرار می‌کند.

داده‌های مورد استفاده در این تحلیل مربوط به دبیرستان‌های استان تهران است و شامل اطلاعاتی درباره مشخصات آموزشی، مالی و دانش‌آموزی این مدارس می‌باشد. فایل highschool.csv شامل ویژگی‌های مختلف مدارس دبیرستانی است که در آن هر ردیف نمایانگر یک دبیرستان و هر ستون نمایانگر یک ویژگی از آن است .هدف از این بررسی، خوشه‌بندی دبیرستان‌ها با استفاده از الگوریتم KMeans و تحلیل الگوهای مشابه میان مدارس مختلف بر اساس ویژگی‌های مشترک آن‌ها است.

ویژگی هایی که در این داده ها موجود است، عبارتند از:

- تعداد درخواست‌ها
- تعداد پذیرش‌ها
- تعداد دانش‌آموزان ثبت‌نام شده
- درصد دانش‌آموزان برتر (۱۰٪ اول کلاس‌های متوسطه)
- درصد دانش‌آموزان برتر (۲۵٪ اول کلاس‌های متوسطه)

- تعداد کل دانش‌آموزان تمام وقت
- تعداد دانش‌آموزان پاره‌وقت (در صورت موجود)
- شهریه سالانه برای مدارس غیردولتی
- هزینه خوابگاه و تغذیه برای مدارس شبانه روزی
- هزینه تقریبی کتاب های درسی
- هزینه شخصی تخمینی دانش‌آموزان
- درصد معلمان دارای مدرک دکتری
- درصد معلمان دارای کارشناسی‌ارشد
- نسبت دانش‌آموزان به معلم
- درصد فارغ‌التحصیلان حامی مدرسه
- هزینه آموزشی به ازای هر دانش‌آموز

الف) برای خوشه‌بندی داده‌های مدارس، باید تعداد خوشه‌ها به دقت تعیین شود. این تعداد را باید با استفاده از روش‌های متداول برای انتخاب تعداد خوشه‌ها مشخص کنید.

ب) هدف این است که خوشه‌بندی با حداقل تعداد iteration انجام شود. الگوریتم خوشه‌بندی را با مقادیر مختلف iteration اجرا کنید و برای هر مقدار، خروجی خوشه‌ها (برچسب‌ها) و زمان اجرای هر iteration را گزارش دهید.

ج) پس از اجرای خوشه‌بندی، ویژگی‌های هر خوشه باید مورد بررسی قرار گیرد. در این مرحله باید از نمودارهای مختلف مانند scatter plot، pair plot، strip plot و swarm plot برای نمایش ویژگی‌های خوشه‌ها و مراکز آنها استفاده کنید. بهتر است برای نمایش خوشه‌ها و مراکز آنها از رنگ های مختلف استفاده کنید. همچنین لازم است جداولی شامل میانگین و انحراف معیار هر ویژگی در هر خوشه ارائه شود تا تفاوت‌ها و شباهت‌های بین خوشه‌ها مشخص گردد.

د) در نهایت، خروجی نهایی باید در قالب یک فایل CSV ذخیره شود که در آن برای هر ردیف، شماره خوشه و مختصات نهایی خوشه‌ها درج شده باشد.

ه) لطفاً دو سوال از سوالات زیر را به انتخاب خود پاسخ دهید:

- آیا مدارس با نسبت پایین‌تر دانش‌آموز به معلم (نسبت کوچک‌تر) نرخ فارغ‌التحصیلی بالاتری دارند؟ این رابطه را با تحلیل آماری و نمودارها اثبات کنید.
- آیا مدارسی که نرخ پذیرش پایین‌تری دارند، میانگین نمرات بالاتری را در آزمون‌ها کسب می‌کنند؟ این رابطه را با تحلیل آماری و نمودارها اثبات کنید.
- آیا مدارسی که سخت‌گیری بیشتری در پذیرش دارند، نرخ فارغ‌التحصیلی بالاتری دارند؟ این رابطه را با تحلیل آماری و نمودارها اثبات کنید.

نکات:

۱. دیتاستی که در اختیار شما قرار گرفته دارای داده‌های خام است. برای اینکه بتوانیم از این داده‌ها برای خوشه‌بندی به درستی استفاده کنیم نیاز به تغییراتی در آن داریم. برای این تغییرات باید به موارد زیر دقت کنید:

- مقادیر مربوط به تعداد درخواست‌ها، تعداد پذیرش‌ها و تعداد ثبت‌نام‌شده‌ها مقادیر خام هستند و تحلیل آنها به خودی خود معنایی ندارد. به عنوان مثال دو مدرسه تعداد پذیرش یکسال دارند اما نرخ پذیرش آنها نسبت به تعداد درخواست‌های آنها میتواند متفاوت باشد. دو ویژگی دیگر به داده ها اضافه کنید که نمایانگر، نرخ پذیرش نسبت به تعداد درخواست‌ها و نرخ ثبت‌نامی ها نسبت به پذیرفته شده‌ها است.
- مقادیر هر ویژگی در بازه‌ی متفاوتی از اعداد هستند. این اختلاف باعث میشود تا یک ویژگی با بازه‌ی اعداد بزرگ بصورت نامتناسبی در خوشه‌بندی الگوریتم KMeans مشارکت کند. به همین دلیل باید بازه‌ی همه اعداد را یکی کنید و نرمالسازی انجام دهید.

۲. میتوانید پیاده‌سازی های مختلف و توابع فاصله مختلف را که در کتابخانه‌هایی مانند sklearn پیاده‌سازی شده‌اند بخوانید.

توضیحات : خروجی‌های این تمرین شامل موارد زیر است:

فایل ارسالی یک فایل Zip است. خروجی‌ها برای هر سوال، در یک زیر شاخه‌ی جدا باشد. همه زیرشاخه‌ها در فایل Zip با نام HW۱_StudentNumber_Fullname.zip گنجانده شود. در صورت درخواست زمان اضافی برای انجام تمرین، ابتدا به دستیار آموزشی در تلگرام پیام دهید و پس از هماهنگی، از ۴ روز کوپن خود استفاده کنید. چنانچه سوالی دارید می‌توانید از دستیار آموزشی درس در گروه تلگرام سوال نمایید.

لطفاً حتماً از قالب آماده گزارش که قبلاً تهیه شده است، استفاده کنید. هر گونه ارسال گزارش خارج از این قالب مورد بررسی قرار نخواهد گرفت.

موفق باشید

رحمتی