شتاب‌دهنده‌های سخت‌افزاری

دانشکده مهندسی کامپیوتر

بهار ۱۴۰۳-۱۴۰۴

استاد درس: دارا رحمتی

طراحی تمرین: زهرا تاکی و متین فیروزبخت

تمرین سوم

تاریخ انتشار : ۱۴۰۴/۰۱/۲۷ - تاریخ تحویل : ۱۴۰۴/۰۲/۱۲

معرفی

هدف از این تمرین پیاده‌سازی سخت‌افزاری یک شبکه عصبی پیچشی با استفاده از معماری systolic array و جریان داده های محتلف میباشد. همانطور که میدانید شبکه های عصبی کانولوشنی یکی ار مهم ترین شیکه ها در یکی ا مهم ترین کاربرد ها یعنی تصاویر هستند. این شبکه ها با داشتن لایه هایی، عملیات کانولوشن را روی داده های دوبعدی انجام میدهد و در وظایف classification و detection و segmentation نفش مهمی دارند. همچنین هرینه بالای محاسبات مربوط به این شبکه ها نیر باعث شده تا مسئله شتابدهی آنها اهمیت بالایی داشته باشد.

در تمرین قصد داریم تا یک شبکه عصبی پیچشی را پس ار آمورش بصورت نرم افراری، بصورت سخت افراری مورد استفاده قراردهیم.

شبکه‌ی LeNet

معماری و لایه‌های شبکه Lenet در درس جرئیات آن در جدول ۲.۲ کتاب مرجع موجود است. این شبکه دارای دو لایه پیچشی با هسته ۵*۵ و دو لایه تمام‌متصل است. معماری این شبکه را در شکل ۱ و لایه‌های آن را در شکل ۲ مشاهده میکنید.

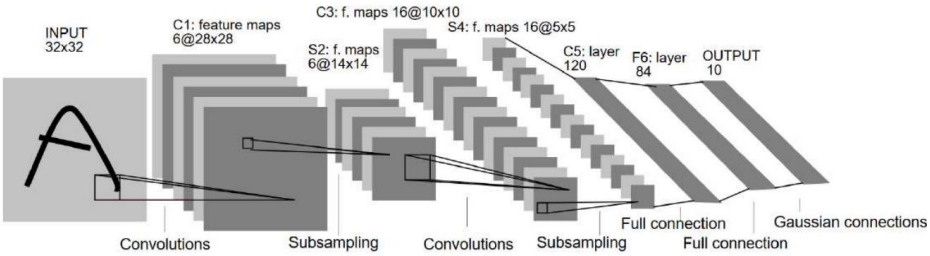

شکل ۱

Layer		Channel	Size	Kernel	Stride	Activation
Input	Image	۱	۳۲*۳۲	-	-	-
۱	Convolution	۶	۲۸*۲۸	۵*۵	۱	tanh
۲	AveragePool	۶	۱۴*۱۴	۲*۲	۲	tanh
۳	Convolution	۱۶	۱۰*۱۰	۵*۵	۱	tanh
۴	AveragePool	۱۶	۵*۵	۲*۲	۲	tanh
۵	Convolution	۱۲۰	۱*۱	۵*۵	۱	tanh
۶	FC	-	۸۴	-	-	tanh
output	FC	-	۱۰	-	-	Sofmax

شکل ۲

مجموعه‌داده

مجموعه داده مورد استفاده در این تمرین Fashion MNIST است. این مجموعه داده با ۶۰۰۰۰ داده آموزشی و ۱۰۰۰۰ داده آزمون تصاویر اندازه ۲۸*۲۸ که بصورت grayscale هستند مناسب شبکه ساده ای مانند LeNet است. این تصاویر مربوط به ۱۰ کلاس از پوشاک هستند. این مجموعه داده را میتوانید از مخزن[۱] آن دریافت کنید. باید توجه کنید که لایه ورودی شبکه LeNet ۳۲*۳۲ است. برای اینکه تصاویر مجموعه داده برای ورودی این شبکه مناسب باشد باید از zero-padding برای افزایش اندازه آن، هم در آموزش و پیاده سازی نرم افزاری و هم در پیاده سازی سخت افزاری استفاده کنید.

جریان‌داده

انواع جریان داده در بخش ۵.۶ کتاب توضیح داده شده اند. همانطور که میدانید جریان داده های مختلف سعی دارند تا ترتیب انجام عملیات یک کانولوشن را مشخص بکنند. در نتیجه جریان داده انتخابی ما میتواند روی معماری شتابدهنده ما تاثیر بگذارد. در این تمرین میخواهیم سه جریان داده ابتدایی weight stationary و output stationary و input stationary را بر روی یک معماری پیاده سازی کنیم. میتوانید معماری هایی که از هرکدام از این جریان داده ها استفاده کرده اند را در جدول ۵.۱ مشاهده کنید.

معماری Systolic array

این معماری یکی از معماری کاربردی برای انجام ضرب ماتریس عمومی است. اما میتوان از معماری شبکه systolic برای طراحی شبکه‌ی واحدهای پردازشی و ارتباط بین آنها استفاده کرد. در این تمرین PE ها در یک معماری systolic قرار دارند. باتوجه به نوع و اندازه عملیات شبکه و همچنین جریان‌داده باید این معماری را با اندازه مناسبی پیاده سازی کنید.

پیاده سازی نرم افزاری

ابتدا لازم است تا شبکه LeNet را بصورت نرم‌افزاری پیاده سازی کنید. برای این مرحله از پیاده سازی میتوانید از Tensorflow یا Pytorch استفاده کنید. سپس شبکه ساخته شده را با استفاده از مجموعه داده معرفی شده آموزش دهید. وزن های به دست آمده از مراحل آموزش را استخراج کنید تا در پیاده سازی سخت افزاری و در فاز inference از آنها استفاده کنید.

[۱] https://github.com/zalandoresearch/fashion-mnist

پیاده‌سازی سخت‌افزاری

همانطور که گفته شد در این بخش باید شبکه‌ی پیچشی را که در مرحله‌ی قبل آموزش دادید، بصورت سخت‌افزاری با یکی از زبان‌های توصیف سخت‌افزاری پیاده‌سازی کنید در نتیجه پیاده سای تنها برای مرحله ی inference است و باید وزن‌های به دست آمده در مرحله قبل را در طراحی خود بخوانید و محاسبات را با آنها انجام دهید.

در این تمرین سه پیاده ساری سخت‌افراری خواهیم داشت که هر کدام دارای یکی ار جریان داده‌های گفته شده روی یک معماری Systolic array است. به عنوان مثال در تصویر ۳ ار تصویر ۵.۱۶ ار کتاب جریان‌داده WS مربوط به neuFlow را مشاهده میکنید. در این تصویر میتوانید ببینید که PE ها عملیات MAC را انجام میدهند. همچنین قرارگیری و ارتباط آنها برای محاسبه مجموع جرئی بصورت Systolic array است. شما باید این طراحی به بصورت ۵*۵ پیاده‌ساری کنید.

یکی ار مهمترین ملاحضات در طراحی شتابدهنده، حافظه است. در این تمرین تمام ورن‌ها در یک حافظه که مدلی ار یک حافظه DRAM با سرعت پایین است ذخیره میشود. مجموع‌های جرئی و خروجی‌ها در یک حافظه مجرا ذخیره میشند. همانطور که میدانید ورن‌های شبکه LeNet حدودا ۶۰هرار است. متناسب با ورن‌های استخراج شده ار مرحله قبل، این حافظه‌ها را طراحی و اندازه آن را مشخص کنید. ورن‌ها را در مارول حافظه دخیره کنید و شبکه را با آنها اجرا کنید.

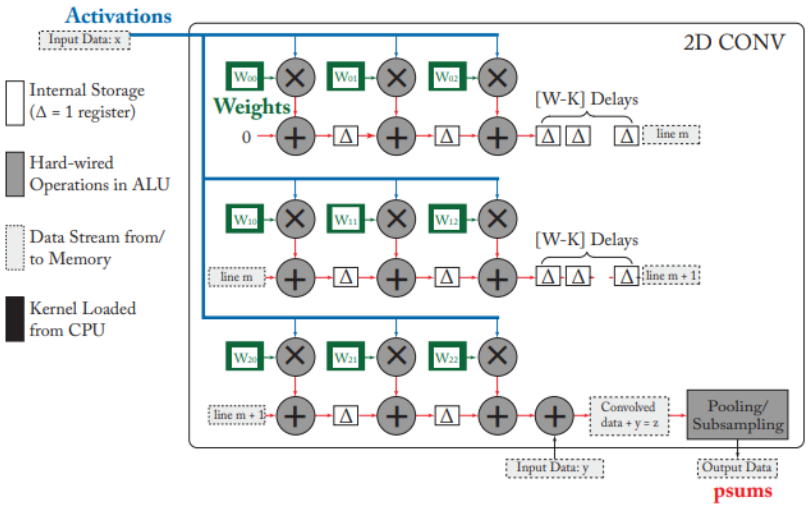

شکل ۳

در طراحی خود به نکات ریر توجه کنید:

ارزیابی

در این مرحله هدف اررریابی طراحی‌های انجام شده با یکدیگر و همچنین با نمونه نرم‌افراری آن است. اررریابی اول مقایسه سرعت inference دو شبکه نرم‌افراری و سخت‌افراری است.

- یک جدول تهیه کنید و در آن رمان inference هر کدام ار پیاده سای های خود را با نمونه نرم افراری آن مقابسه کنید. سپس به سوالات ریر پاسخ دهید.
  - رمان inference سخت‌افرار خود را چگونه محاسبه میکنید؟
  - این مقایسه عادلانه نیست. چرا؟
  - برای اینکه مقایسه عادلانه ار سرعت شتابدهنده های خود داشته باشیم پیشنهاد شما چیست؟

ارزیابی دوم مقایسه سه پیاده‌سازی سخت‌افزاری است. پس از سنتز و پیاده‌سازی این سه طراحی، با استفاده از گزارش های ابزار vivado آنها را از نظر total on chip power و throughput مقایسه کنید. همانطور که میدانید throughput به معنی تعداد بیت‌های پردازش شده در واحد زمان است. با استفاده از تنظیمات و گزارش های مربوط به timing پارامتر های مورد نیاز خود برای محاسبه throughput را استخراج و آن را محاسبه کنید. تحلیل خود را از این مقایسه‌ها بیان کنید.

امتیازی

در این بخش قصد داریم از دو سطح حافظه استفاده کنیم. طراحی خود را به گونه‌ای تغییر دهید تا ورن‌های موردنیاز در محاسبات پیش‌رو را از حافظه سطح دوم به سطح دوم بنویسید. سپس از ورن‌های حافظه سریعتر برای محاسبات استفاده کنید. حافظه سطح اول یک حافظه به اندازه ۱ Kbyte است که نمونه‌ای از یک حافظه SRAM با سرعت بالا است. این حافظه میتواند در یک کلاک مقدار آدرس را روی خروجی قرار بدهد. این حافظه را به گونه‌ای پیاده‌سازی کنید تا در یک کلاک از آن مقدار بخوانید. حافظه سطح دوم همان حافظه ای است که در قسمت قبل پیاده‌سازی کرده‌اید. اما باید کند بودن آن را با استفاده از پیاده‌سازی یک شمارنده یا یک ماشین‌حالت شبیه‌سازی کنید. خواندن از این حافظه چهار کلاک طول میکشد.

نکات

برای انجام zero padding قید خاصی وجود ندارد. میتوانید تصاویر اصلی را تغییر دهید یا بعد از خواندن تصاویر در هاردور با استفاده از یک پیش پرداش آنها را تغییر دهید.

۱- پیاده‌سازی نرم‌افزاری

در این بخش به دنبال فهم دقیق الگوریتم‌های آموزش و استفاده اشاره شده در درس و محاسبات مربوط به این الگوریتم‌ها هستیم. با استفاده از زبان پایتون[۲] این شبکه را پیاده‌سازی کنید و برای داده‌های موجود آموزش دهید. نکات زیر را در نظر بگیرید:

- برای خواندن مجموعه‌داده میتوانید از مجموعه‌داده NIST در scikit-learn استفاده کنید.
- برای تابع فعالساز لایه مخفی از تابع واحد یک‌سوشده‌ی خطی[۳] و لایه خروجی از سیگموئید[۴] استفاده کنید.
- پیاده‌سازی هر کدام از ۹ مراحله‌ی الگوریتم را در گزارش خود شرح دهید.
- در پیاده‌سازی مجاز به استفاده از کتابخانه‌های شبکه‌های عصبی نیستید و محاسبات باید با قابلیت‌های پایه‌ای زبان برنامه نویسی انجام شود.
- داده‌های خود را به دسته‌ی آموزش و آزمون تقسیم کنید و با استفاده از داده‌های آزمون Dataset موجود، دقت شبکه‌ی خود را گزارش کنید.
- نحوه محاسبه دقت خود را گزارش کنید.
- وزن‌های به دست آمده بعد از مرحله‌ی آموزش را ذخیره و گزارش کنید.

۱- Python
۲- ReLU
۳- Sigmoid

۲- پیاده‌سازی سخت‌افزاری

در این بخش باید شبکه‌ی MLP را که در مرحله‌ی قبل آموزش دادید، بصورت سخت‌افزاری با یکی از زبان‌های توصیف سخت‌افزاری پیاده‌سازی کنید. در این مرحله لازم به اجرای مرحله‌ی آموزش نیست. در واقع مرحله‌ی آموزش بصورت سخت‌افزاری انجام نمیشود. ما تنها نیاز به اجرای بخش inference و feed forward داریم. در نتیجه باید وزن‌های به دست آمده در مرحله قبل را در طراحی خود بخوانید و محاسبات را با آنها انجام دهید. در طراحی به نکات زیر توجه کنید.

- برای طراحی از ابزار Vivado استفاده کنید.
- مراحل سنتز[۵] و پیاده‌سازی[۶] باید به درستی برای طراحی شما انجام شود.
- پس از انجام مراحل سنتز و پیاده‌سازی، تصویر شماتیک به‌دست‌آمده و پارامترهای دیگری که Vivado گزارش میکند (مانند total power و...) را قید کنید.
- پس از انجام مرحله‌ی Inference با استفاده از داده‌های آزمون در Dataset مقدار دقت مدل را با مدل نرم‌افزاری مقایسه کنید. دقت این دو پیاده‌سازی باید تا حد ممکن به یکدیگر نزدیک باشند.
- برای خواندن داده‌ها در کد HDL از خواندن فایل‌های مجموعه‌داده‌ای که در اختیار شما قرار گرفته‌است استفاده کنید.
- نحوه محاسبه دقت را گزارش کنید.

توضیحات : خروجی‌های این تمرین شامل موارد زیر است:

فایل ارسالی یک فایل Zip است. خروجی‌ها برای هر سوال، در یک زیر شاخه‌ی جدا باشد. همه زیرشاخه‌ها در فایل Zip با نام HW۱_StudentNumber_Fullname.zip گنجانده شود. در صورت درخواست زمان اضافی برای انجام تمرین، ابتدا به دستیار آموزشی در تلگرام پیام دهید و پس از هماهنگی، از ۴ روز کوپن خود استفاده کنید. چنانچه سوالی دارید می‌توانید از دستیار آموزشی درس در گروه تلگرام سوال نمایید.

لطفاً حتماً از قالب آماده گزارش که قبلاً تهیه شده است، استفاده کنید. هر گونه ارسال گزارش خارج از این قالب مورد بررسی قرار نخواهد گرفت.

موفق باشید

رحمتی

۴- Synthesis
۵- Implement