شتاب‌دهنده‌های سخت‌افزاری
دانشکده مهندسی کامپیوتر
بهار ۱۴۰۳-۱۴۰۴
استاد درس: دارا رحمتی
طراحی تمرین: زهرا تاکی - متین فیروزبخت - علیرضا تقوی‌زاده
تمرین ششم
تاریخ انتشار : ۱۴۰۴/۰۳/۰۷ - تاریخ تحویل : ۱۴۰۴/۰۳/۱۷

معرفی

با توجه به پرکاربرد بودن شتاب‌دهنده‌ها در دستگاه‌هایی که با محدودیت منابع انرژی مواجه‌اند، بهینه‌سازی مصرف انرژی برای افزایش بازدهی و حفظ پایداری عملیاتی و افزایش طول عمر باتری ضروری است. در طراحی شتاب‌دهنده‌های سخت‌افزاری برای شبکه‌های عصبی، ابزارهای ارزیابی مصرف انرژی نقش حیاتی دارند. این ابزارها به طراحان امکان می‌دهند تا میزان انرژی مصرفی در بخش‌های مختلف سیستم را تحلیل کرده و نقاط پرمصرف را شناسایی کنند. همچنین، در مقایسه و انتخاب معماری‌های مختلف و تصمیم‌گیری‌های طراحی کمک میکنند. در این تمرین، هدف آشنایی با استفاده از ابزارهای ارزیابی مصرف انرژی در شتاب‌دهنده‌های سخت‌افزاری شبکه‌های عصبی است از جمله Timeloop-Accelergy و MAESTRO است.

Accelergy و Timeloop

Timeloop و Accelergy دو ابزار متن‌باز هستند که برای طراحی و ارزیابی شتاب‌دهنده‌های سخت‌افزاری شبکه‌های عصبی توسعه یافته‌اند. Timeloop ابزاری برای مدلسازی نگاشت داده‌ها[۱]، زمان‌بندی[۲] و مکان‌یابی در حافظه‌های سلسله‌مراتبی[۳] یک شتاب‌دهنده است و به طراح کمک می‌کند تا کارایی اجرای شبکه عصبی روی معماری دلخواه را تحلیل کند. در کنار آن، Accelergy ابزاری برای برآورد دقیق انرژی مصرفی اجزای مختلف شتاب‌دهنده است. این دو ابزار معمولاً به‌صورت ترکیبی استفاده می‌شوند تا ارزیابی همزمان زمان اجرا و مصرف انرژی در معماری‌های سفارشی به‌دست آید. در این تمرین هدف یادگیری این دو ابزار است.

سخت‌افزار شتاب‌دهنده

برای استفاده از این ابزارها در ابتدا نیاز است جزئیات سخت‌افزاری شتاب‌دهنده خود را بر اساس مدل‌سازی که این ابزارها ارائه می‌کنند، پیاده‌سازی کنید. به عنوان یک شتاب‌دهنده می‌توانید با مطالعه مقاله Simba[۴] و درک آن سپس از جزییات سخت‌افزاری آن استفاده کنید که براساس ساختار آرایه تپنده[۵] است. صرفا از جزئیات سخت‌افزاری یک chip این شتاب‌دهنده استفاده کنید.

---

۱ Data mapping
۲ Scheduling
۳ Memory hierarchy placement
۴ Simba: Scaling Deep-Learning Inference with Multi-Chip-Module-Based Architecture
۵ Systolic array

نصب

برای نصب از لینک قرارداده‌شده در قسمت لینک‌ها استفاده کنید. استفاده از روش اول (Docker) پیشنهاد میشود. در صورت انتخاب این روش، توجه کنید که بسته به معماری CPU خود لازم است متغییر DOCKER_ARCH را مشخص کنید.

مدلسازی و اجرا

مدل‌سازی با استفاده از ابزار Timeloop

با استفاده از ابزار Timeloop، معماری بخش آرایه تپنده مربوط به شتاب‌دهنده Simba را مدل‌سازی کنید. در این فرآیند، باید نحوه نگاشت عملیات، زمان‌بندی اجرای داده‌ها، و سلسله‌مراتب حافظه تعریف شود.
جزئیات مدل‌سازی شامل تعیین ابعاد شبکه آرایه، مشخصات پورت‌های ورودی و خروجی، ظرفیت و نوع هر سطح از حافظه و نیز الگوی جریان داده[۶] باید به‌صورت شفاف ارائه شود. در گزارش خود مشخص نمایید که هر واحد معماری که شامل عناصر محاسباتی، بافرها و مسیرهای ارتباطی است چگونه تعریف و پیکربندی شده و چه پارامترهایی برای هر بخش انتخاب شده‌است.

برآورد انرژی با استفاده از ابزار Accelergy

با استفاده از ابزار Accelergy، انرژی مصرفی مدل ساخته‌شده در قسمت قبل را تخمین بزنید. در این مرحله، باید فایل‌های پیکربندی معماری و پارامترهای فناوری متناسب با ساختار حافظه‌های مبتنی بر SRAM تدوین و استفاده شوند. توضیح دهید که چگونه ماژول‌های مختلف معماری از جمله حافظه‌های محلی[۷]، حافظه‌های سطح بالاتر[۸]، و واحدهای محاسبه در مدل انرژی لحاظ شده‌اند و خروجی‌های عددی انرژی مصرفی در هر بخش را گزارش و تحلیل نمایید.

MAESTRO

MAESTRO ابزاری برای تحلیل سریع جریان داده‌ها در شتاب‌دهنده‌های شبکه عصبی و همچنین ساده‌سازی جستجوی فضای طراحی است. این ابزار تأثیر انواع مختلف جریان داده را بر مصرف حافظه، پهنای باند و انرژی بررسی می‌کند و برای مقایسه و ارزیابی استراتژی‌های نگاشت در طراحی معماری بسیار کاربردی است.

---

[۶] Dataflow
[۷] Locad RF
[۸] GLB

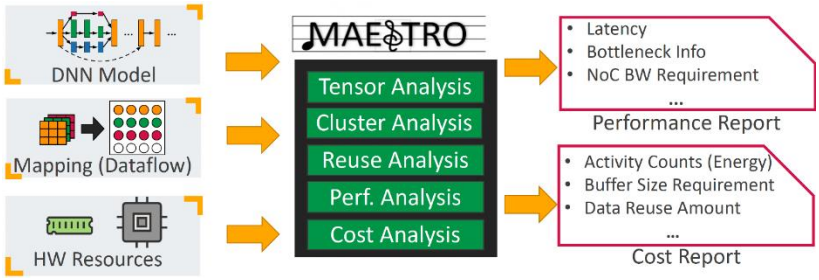

شکل ۱ – workflow ابزار MAESTRO

این ابزار پارامترهای زیر را به عنوان ورودی دریافت می‌کند:

- مدل شبکه عصبی مورد نظر که می‌توان با استفاده از Pytorch/Keras تولید کرد.
- اطلاعات سخت‌افزار مورد نظر
- شیوه‌ی نگاشت

نصب

با استفاده از لینک قرارگرفته در قسمت لینک‌ها، این ابزار را دانلود میتوانید بر روی سیستم عامل Linux کامپایل کنید. همچنین می‌توانید از ماشین مجازی نیز استفاده نمایید. در این صورت از نصب بودن پیش‌نیازهای libboost-all-dev و scons اطمینان حاصل کنید. همچنین میتوانید از Docker image ارائه‌شده که نسخه آموزشی آن است نیز استفاده کنید.

اجرا

به نکات زیر توجه کنید.

- در هر اجرا با مشخص کردن پارامترهای مناسب، تمام خروجی‌های بدست آمده را ذخیره نمایید.
- ترتیب سوالات لزوما ترتیب فهم و اجرای ابزار را مشخص نمی‌کند.
- در نظر داشته باشید که هر زمان تاثیر دو پارامتر را مقایسه می‌کنیم، باید سایر پارامترها را ثابت در نظر بگیریم. مقادیر این پارامترها اختیاری است ولی آن را ذکر نمایید. میتوانید از مقادیر پیشفرض استفاده کنید.
- خروجی تمام حالت‌های گفته شده را پس از اجرا به طور کامل ذخیره نمایید.

۱- با بررسی آدرس tools/frontend/dataflow در مخزن پروژه MAESTRO قرارگرفته در قسمت لینک‌ها و فایل‌های موجود در آن، انواع dataflowهای ارایه شده را مشخص کنید و هر کدام را به اختصار توضیح دهید. برای توضیح dataflowهای موجود نیاز است که به طور خیلی مختصر بعضی از مقالات را نیز بررسی نمایید. به طور خاص مقاله‌ی MAERI را می‌توانید مشاهده نمایید.

۲- منظور از کلمات کلیدی زیر در توصیف dataflow چیست؟

- TemporalMap
- SpatialMap
- Cluster

۳- با استفاده از Pytorch/Keras مدل‌های شبکه عصبی با پارامترهای ورودی زیر تولید و عمده تفاوت خروجی نهایی را برای این دو نوع ورودی گزارش نمایید.

a. مدل اول : Input size : ۳,۲٤٤,۲٤٤

b. مدل دوم : Input size : ۳, ٤۸۸, ٤۸۸

c. مدل ورودی را mobilenet_v۲ در نظر بگیرید.

٤- ابزار MAESTRO چه پارامترهایی را به عنوان خروجی آنالیز شتاب‌دهنده به ما می‌دهد؟ مهمترین آنها از نظر شما کدام هستند و تاثیر بیشتری بر روی انتخاب پارامترهای ورودی دارد؟

لینک‌ها

مقاله Simba
https://drive.google.com/file/d/۱AKsFU۱Usnv۵DdXms۲g۶Ny۰۹xamxjnkX۹/view

نصب Timeloop
https://timeloop.csail.mit.edu/v۴/installation

نصب MAESTRO
http://maestro.ece.gatech.edu/docs/build/html/installation.html

مخزن پروژه MAESTRO
https://github.com/maestro-project/maestro

مقاله Maeri
https://synergy.ece.gatech.edu/tools/maeri/maeri-tutorial-hpca-۲۰۱۹/

توضیحات : خروجی‌های این تمرین شامل موارد زیر است:

فایل ارسالی یک فایل Zip است. خروجی‌ها برای هر سوال، در یک زیر شاخه‌ی جدا باشد. همه زیرشاخه‌ها در فایل Zip با نام HW٦_StudentNumber_Fullname.zip گنجانده شود. در صورت درخواست زمان اضافی برای انجام تمرین، ابتدا به دستیار آموزشی در تلگرام پیام دهید و پس از هماهنگی، از ۴ روز کوپن خود استفاده کنید. چنانچه سوالی دارید می‌توانید از دستیار آموزشی درس در گروه تلگرام سوال نمایید.

لطفاً حتماً از قالب آماده گزارش که قبلاً تهیه شده است، استفاده کنید. هر گونه ارسال گزارش خارج از این قالب مورد بررسی قرار نخواهد گرفت.